

# Introdução à Análise de Dados FAE

## Trabalho 2

Diogo Caffonso  
Matrícula: 202010115711

## Exercício 1:

Para o método dos mínimos quadrados, existe uma função  $S(a, b)$ , sendo  $a$  e  $b$  os coeficientes angular e linear da reta proposta, respectivamente, tal que esta deva ser minimizada para garantir a melhor reta que se adéque aos pontos. Para quando se tratam de dados tais que os erros para  $y_i$  variam, isto é, para o MMQ ponderado, a função  $S(a, b)$  é dada por:

$$S(a, b) = \sum_{i=1}^N \left[ \frac{y_i - (ax_i + b)}{\sigma_i} \right]^2 > 0$$

Expandindo a equação, pode-se ver que:

$$\frac{1}{\sigma^2} = \sum_{i=1}^N \frac{1}{\sigma_i^2} \quad \& \quad w_i = \left( \frac{\sigma}{\sigma_i} \right)^2 \rightarrow \sum_{i=1}^N w_i = 1$$

Visto que  $\sigma^2$  e  $\bar{x}^2$  são positivos,  $a$  e  $b$  são dados pelas mesmas expressões que no caso de um ajuste linear não ponderado, isto é:

$$\begin{cases} a = \frac{\sigma_{xy}}{\sigma_x^2} = r \frac{\sigma_y}{\sigma_x} \\ b = \bar{y} - a\bar{x} \end{cases}$$

Reescrevendo os parâmetros, temos:

$$\begin{cases} a = \frac{\sigma^2}{\sigma_x^2} \sum_{i=1}^N \frac{(x_i - \bar{x})}{\sigma_i^2} y_i \\ b = \sum_{i=1}^N \frac{\sigma^2}{\sigma_x^2} y_i - a\bar{x} \end{cases}$$

Agora, de acordo com a fórmula de propagação de erros, as incertezas, desta forma, são dadas por:

$$\begin{cases} \sigma_a^2 = \frac{\sigma^2}{\sigma_x^2} \\ \sigma_b^2 = \overline{x^2} \sigma_a^2 \end{cases}$$

E, para minimizar a função  $S(a, b)$ , devem ser tiradas suas derivadas parciais em relação a  $a$  e  $b$  e igualar a zero, ou seja:

$$\begin{cases} \frac{\partial S}{\partial a} = -2 \sum_{i=1}^N \frac{x_i}{\sigma_i^2} (y_i - ax_i - b) = 0 \\ \frac{\partial S}{\partial b} = -2 \sum_{i=1}^N \frac{1}{\sigma_i^2} (y_i - ax_i - b) = 0 \end{cases}$$

Este sistema pode ser reescrito da seguinte forma:

$$\begin{cases} \left( \sum_{i=1}^N \frac{x_i^2}{\sigma_i^2} \right) a + \left( \sum_{i=1}^N \frac{x_i}{\sigma_i^2} \right) b = \sum_{i=1}^N \frac{x_i y_i}{\sigma_i^2} \\ \left( \sum_{i=1}^N \frac{x_i}{\sigma_i^2} \right) a + \left( \sum_{i=1}^N \frac{1}{\sigma_i^2} \right) b = \sum_{i=1}^N \frac{y_i}{\sigma_i^2} \end{cases}$$

e pode ser simplificado para:

$$\begin{cases} \overline{x^2} a + \overline{x} b = \overline{xy} \\ \overline{x} a + b = \overline{y} \end{cases}$$

que, por fim, entrega as seguintes soluções para  $a$  e para  $b$ :

$$a = \frac{\sigma_{xy}}{\sigma_x^2} \quad \& \quad b = \overline{y} - a \overline{x}$$

com incertezas:

$$\sigma_a = \frac{\sigma}{\sigma_x} \quad \& \quad \sigma_b = \sigma_a \sqrt{\overline{x^2}}$$

## Exercício 2:

Sabemos que:

$$\sigma = \frac{N_T - N_B}{\mathcal{L}}$$

Onde:

$$N_{\text{total}} = N_T = 2567,0 \text{ eventos}$$

$$N_{\text{background}} = N_B = 1223,5 \text{ eventos}$$

$$\mathcal{L} = 25 \text{ fb}^{-1}$$

Para a incerteza estatística  $\Delta\sigma_{est}$ , faz-se:

$$\Delta\sigma_{est} = \frac{\sqrt{\Delta N_T^2 + \Delta N_B^2}}{\mathcal{L}}$$

em que, para a distribuição de Poisson:  $\Delta N_T = \sqrt{N_T}$  e  $\Delta N_B = \sqrt{N_B}$ .

Agora, para a incerteza sistemática  $\Delta\sigma_{sis}$ , basta fazer:

$$\Delta\sigma_{sis} = 10\% \sigma$$

que leva ao resultado:

$$\sigma = (53,74 \pm 2,46_{(\text{estatística})} \pm 5,37_{(\text{sistemática})}) \text{ fb}$$

### Exercício 3:

A distribuição de Poisson pode ser dada pela forma:

$$P_{(n;s,b)} = \frac{(s+b)^n e^{-(s+b)}}{n!}$$

Do problema, temos que  $n = 0$  e  $b = 0,07$ . Assim, a equação se reduz a:

$$P_{(n=0;s,b=0,07)} = e^{-(s+0,07)}$$

Agora, para calcular até quantos eventos esperados podemos excluir com 95% de C.L, fazemos:

$$P_{(n=0;s,b=0,07)} = e^{-(s+0,07)} = 100\% - 95\% = 0,05$$

e, resolvendo para  $s$ , encontramos:

$$s \simeq 2,93$$

Ou seja, são previstos mais que 2,93 eventos.

## Exercício 4:

Para demonstrar que  $\chi^2/ndf$  tender a 1 indica um bom fit, parte-se de:

$$\chi^2 = \sum_{i=1}^n \frac{(y_i - f(x_i))^2}{\sigma_i^2}$$

para incertezas iguais:

$$\chi^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - f(x_i))^2$$

Para quando  $n \rightarrow \infty$ ,  $\sigma^2$  pode ser aproximado por:

$$\sigma^2 \simeq \frac{1}{n} \sum_{i=1}^n (y_i - f_v(x_i))^2 \rightarrow n \simeq \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - f_v(x_i))^2$$

em que  $f_v(x_i)$  é a função verdadeira. Por simplicidade,  $f(x_i) = f$ . Então:

$$\begin{aligned} n &\simeq \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - f_v + f - f)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n [(y_i - f) + (f - f_v)]^2 = \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - f)^2 + \frac{1}{\sigma^2} \sum_{i=1}^n (f - f_v)^2 + \frac{2}{\sigma^2} \sum_{i=1}^n (y_i - f)(f - f_v) \end{aligned}$$

Pode-se ver que o primeiro termo é igual a  $\chi^2$ . O terceiro termo se anula para quando  $n \rightarrow \infty$ . Para o segundo termo, temos que

$(f - f_v)^2 \simeq \sigma_f^2$ , que é a variância para a função ajustada, que também pode ser escrita da forma:

$$\sigma_f^2 = f_1^2 \sigma_{a_1}^2 + \dots + f_p^2 \sigma_{a_p}^2 = \sum_{k=1}^p f_k^2 \sigma_{a_k}^2 = \sum_{k=1}^p f_k^2 m_{kk}$$

assim, podemos ver que:

$$\begin{aligned} \frac{1}{\sigma^2} \sum_{i=1}^n (f - f_v)^2 &= \frac{1}{\sigma^2} \sum_{i=1}^n \sigma_f^2 = \frac{1}{\sigma^2} \sum_{i=1}^n \sum_{k=1}^p f_k^2 m_{kk} = \\ &= \sum_{k=1}^p \sum_{i=1}^n \frac{f_k^2}{\sigma^2} m_{kk} = \sum_{k=1}^p M_{kk} m_{kk} \end{aligned}$$

e, já que os parâmetros  $a_k$  são independentes,  $M_{kk} m_{kk} = 1$ . Ou seja:

$$\frac{1}{\sigma^2} \sum_{i=1}^n (f - f_v)^2 = \sum_{k=1}^p 1 = p$$

Assim, substituindo os três termos de volta, obtemos:

$$\begin{aligned} n \simeq \chi^2 + p + 0 \rightarrow \chi^2 \simeq n - p = ndof \rightarrow \chi^2 \simeq ndof \rightarrow \\ \rightarrow \frac{\chi^2}{ndof} \simeq 1 \end{aligned}$$

que mostra que, para quando  $\chi^2/ndf$  tende a 1, o fit de uma dada função  $f$  se mostra satisfatório.